Universidad de los Andes
Programa Ciencia de Datos
Aplicaciones en Ciencia de Datos (DATA-1002)
Profesores: Nicolas Mejia Martinez, Nicolas Felipe Suarez Ariza

Laboratorio 10: Sesgos

Con relación al desarrollo y entrega del taller, tenga en cuenta lo siguiente:

- El desarrollo del taller se debe llevar a cabo en grupos de máximo 3 personas.
- El uso de herramientas de inteligencia generativa durante el desarrollo del taller está estrictamente prohibido.
- La solución del taller debe ser subido al link disponible en bloque neón antes del fin de clase.
- Todo el taller debe desarrollarse en un único archivo .ipynb que deberá tener el código pedido y la respuesta a cada una de las preguntas del taller.
- No se calificarán envíos posteriores a esta fecha y hora.
- Cualquier sospecha de fraude será manejada de acuerdo con el reglamento de la Universidad.

FinAcceso

FinAcceso es una entidad financiera que ofrece microcréditos para emprendedores y hogares de cuatro zonas de una ciudad colombiana. Para estudiar su operación, la entidad ha consolidado solicitudes de crédito y una estimación del mercado potencial por zona. Las solicitudes se evalúan mediante un puntaje de riesgo heredado y otros criterios de elegibilidad.

La gerencia quiere reasignar el presupuesto de asesoría financiera y ha presentado la siguiente recomendación:

> "Deberíamos concentrar la asesoría en las zonas que generan más créditos aprobados. Allí parece existir mayor demanda y el dinero se aprovecharía mejor. Las zonas con pocas aprobaciones podrían recibir menos acompañamiento"

Ustedes integran el equipo que debe auditar esta afirmación ANTES de ejecutar los cambios. Se espera una postura sustentada en evidencia, no una conclusión preconcebida a favor o en contra de la gerencia.

Para este fin, ustedes reciben los siguientes datasets:

- **FinAcceso_solicitudes_credito.csv**: Una fila por solicitud radicada: zona, canal, ingreso, historial crediticio, puntaje, carga financiera, monto solicitado y decisión.
- **FinAcceso_mercado_potencial.csv**: Una fila por zona con una estimación administrativa de hogares potencialmente interesados en productos financieros.

Tenga en cuenta que:

- Un puntaje de riesgo más alto indica MENOR riesgo estimado.
- *carga_financiera* representa la proporción del ingreso comprometida en obligaciones mensuales (por ejemplo, $0.40 = 40\,\%$).
- La base no contiene información sobre mora futura ni sobre personas que nunca presentaron una solicitud.

1. ¿Qué decisión estamos evaluando?
   - Identifiquen dos supuestos implícitos en la recomendación de la gerencia. ¿Por qué necesitan verificarlos antes de tomar decisiones?
   - Definan a qué población describe cada archivo y mencionen un grupo que podría quedar invisible si solo se analizan las solicitudes registradas.
   - Formulen una pregunta concreta y verificable para auditar la propuesta de redistribución de asesoría.
2. ¿Dónde están las solicitudes y dónde está el mercado potencial?
   - Inspeccionen las dos fuentes y únanlas por zona. Revisen el resultado de la unión.
   - Construyan una tabla por zona con: hogares potenciales, solicitudes recibidas, porcentaje del total de solicitudes y solicitudes por cada 1.000 hogares potenciales.
   - ¿Una zona con menos solicitudes implica necesariamente menor necesidad del servicio? Justifiquen su posición con datos.
3. ¿Aprobar muchos créditos significa atender mejor?
   - Calculen la tasa global de aprobación. Después, por zona, reporten el número de solicitudes, el número de aprobaciones y la tasa de aprobación.

- Identifiquen si el orden de las zonas cambia cuando se comparan números absolutos frente a tasas. ¿Qué interpretación sería engañosa?
- Propongan una variable adicional del archivo que valga la pena examinar antes de comparar las tasas entre zonas y expliquen el por qué.

4. Una diferencia que podría tener varias explicaciones

   - Agrupen el puntaje de riesgo en tres intervalos: menor de 610, de 610 a 689, 690 o más. En cada intervalo comparen, entre historial crediticio Amplio y Limitado, el número de solicitudes y el porcentaje de aprobaciones.
   - ¿Persisten diferencias al comparar personas en el mismo intervalo de puntaje? Apoyen su respuesta en una tabla de resultados.
   - ¿Podemos concluir que el historial crediticio causa la diferencia o que el proceso es discriminatorio? Indiquen qué otras variables, aspectos del puntaje y datos faltantes sería importante revisar.

5. El impacto de una decisión basada en datos

   - Supongan que FinAcceso recorta la asesoría presencial en las zonas con menos aprobaciones. Identifiquen dos posibles consecuencias: una inmediata y otra que pueda agravarse con el tiempo.
   - ¿Qué grupos podrían verse más afectados por la decisión? Relacionen su respuesta con al menos un resultado de los puntos 2 a 4.
   - Propongan dos estrategias que podrían utilizar para limitar los daños que puede traer la decisión: una relacionada con la calidad o cobertura de los datos y otra sobre la implementación y monitoreo de la decisión.

6. Veredicto para el comité de FinAcceso

   - Escriban una recomendación ejecutiva de máximo 160 palabras: aprobar, modificar o aplazar la propuesta, con al menos dos cifras de su análisis, una limitación que siga abierta y un siguiente paso concreto.
   - Cierren con una frase que explique ¿qué sería irresponsable afirmar públicamente con estos datos, aunque resulte tentador?